ENASTIC
Ecole Nationale Supérieure des TIC

Projet de Fin d'Études

En vue de l'obtention du **Diplôme de Licence en Informatique**

THÈME

CyberSentinel-LLM

Plateforme Cognitive de Cybersécurité Conversationnelle

pour la Détection Contextuelle et la Neutralisation Adaptive des Menaces Réseau

Présenté par :

M. YAKHOUB MAHAMAT HAMDO

Directeur de mémoire :

Dr. MOUAZ MICKAIL

Enseignant chercheur en IA

Année Universitaire : 2025-2026

Sommaire

1. Contexte et problématique

2. Notre approche

3. Architecture et fonctionnement

4. La plateforme en images

5. Tests et résultats

6. Démonstration

7. Bilan et perspectives

Contexte : la cybersécurité au Tchad

- En 2025, le Tchad compte **2,74 millions d'internautes** et **14,5 millions de connexions mobiles**
- La digitalisation avance vite, mais les outils de cybersécurité restent **limités**
- Peu de SOC nationaux, peu d'experts locaux, dépendance à l'étranger

Un exemple concret

Le **10 janvier 2024**, une attaque DDoS a coupé **tout Internet** au Tchad pendant plusieurs heures.

La cybersécurité n'est plus un luxe : c'est une nécessité.

Le problème

Les outils classiques (Snort, Suricata...) fonctionnent avec des **règles fixes** :

> "Si tu vois EXACTEMENT ce motif → alerte"

- **Limite 1** : une attaque **nouvelle** (jamais vue) passe inaperçue
- **Limite 2** : les alertes sont **trop techniques** pour un analyste débutant (ex : `score=0.87, rule=ml_iforest_anomaly` — et maintenant ?)

Notre question centrale

Comment détecter des attaques **même inconnues**, les **expliquer en langage simple**, tout en gardant un **humain** dans la décision finale — sur une machine **sans GPU** ?

L'idée : 3 cerveaux qui travaillent ensemble



Principe central : Human-in-the-Loop

L'IA **analyse, explique, recommande** — mais c'est toujours **l'analyste humain** qui décide de bloquer ou non.

Objectif général

Concevoir et réaliser une plateforme qui combine **détection d'anomalies** (Machine Learning), **explication contextuelle** (RAG + MITRE ATT&CK + LLM local), et **neutralisation adaptive** des menaces validée par un humain — pour aider un analyste SOC à comprendre et réagir plus vite.

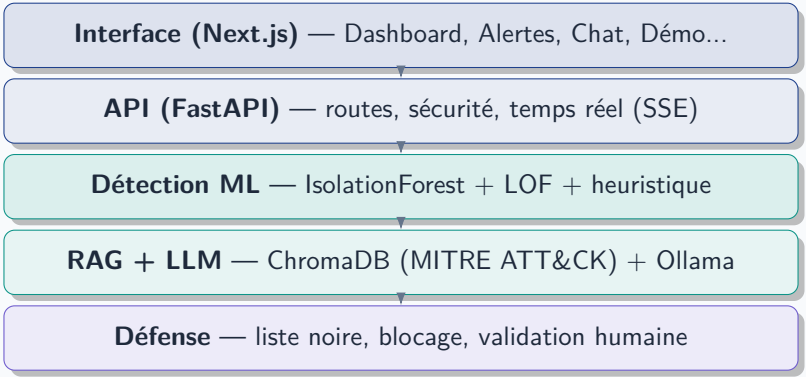
Contraintes respectées :

- Fonctionne **sans GPU** (CPU + 16 Go RAM)
- **100% local** — aucune donnée envoyée au cloud

Technologies clés :

- Backend : Python / FastAPI
- Frontend : Next.js / React
- Base : SQLite + ChromaDB

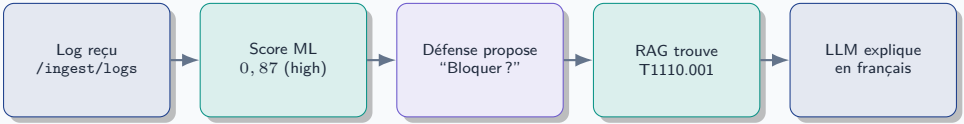
Architecture globale — 5 couches



Architecture **monolithique modulaire** : simple à déployer localement, sans serveur complexe.

Comment ça marche ? Exemple concret

Une connexion SSH échoue 3 fois en 1h, à 3h du matin, depuis une IP inconnue.



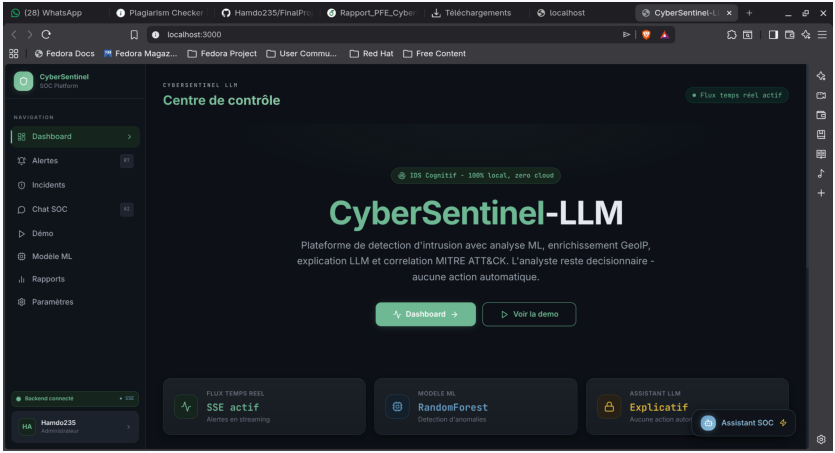
Score de confiance final

$$\text{confiance} = 0{,}4 \times \text{score}_{ML} + 0{,}3 \times \text{score}_{RAG} + 0{,}3 \times \text{score}_{LLM}$$

$$0{,}4{\times}0{,}87 + 0{,}3{\times}0{,}82 + 0{,}3{\times}0{,}89 = \mathbf{0{,}861} \rightarrow \textbf{86\% de confiance}$$

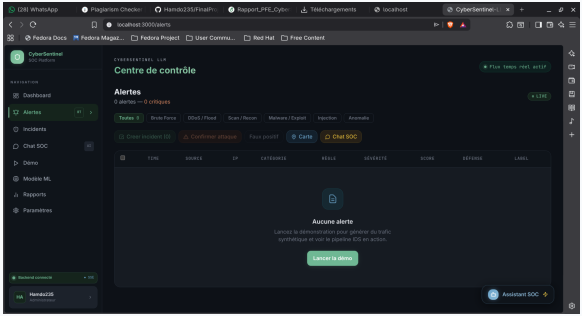
L'analyste reçoit une notification, **décide**, et l'IP est bloquée pendant 30 min seulement si **lui** l'approuve.

Tableau de bord SOC

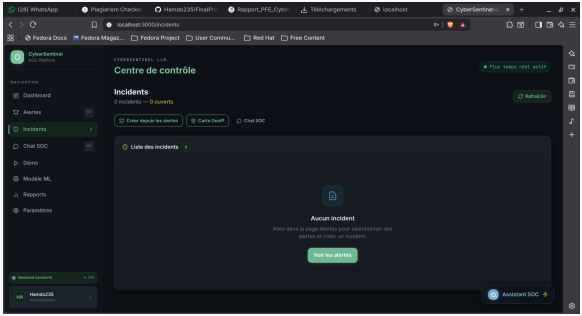


Vue temps réel : alertes, carte des attaques, indicateurs clés

Alertes et incidents

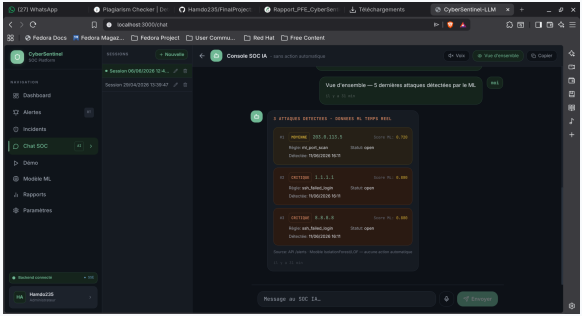


Liste des alertes détectées

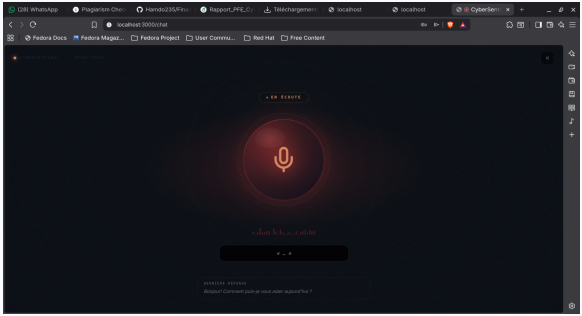


Incidents groupés depuis les alertes

Assistant conversationnel (Chat SOC)

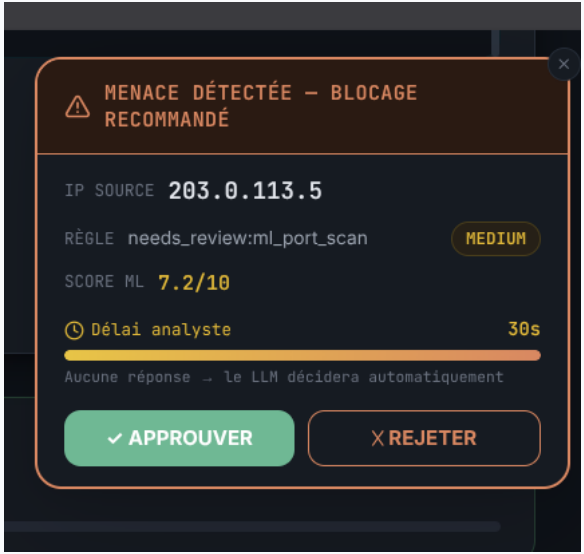


Discussion en langage naturel avec l'IA

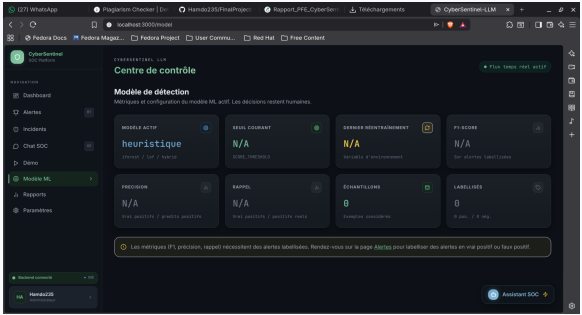


Mode vocal (voix → texte → voix)

Neutralisation et suivi



Notification de blocage : validation humaine requise



Métriques du modèle ML

Tests automatisés

Backend — pytest

- `test_defense.py` — décision, approbation, révocation
- `test_ip_blacklist.py` — ajout, blocage, expiration
- `test_detection.py` — features ML, fallback heuristique

Frontend — Vitest

- `auth.test.ts` — login, register, 2FA TOTP
- DOM simulé avec `happy-dom`

Résultat global

Tous les tests passent

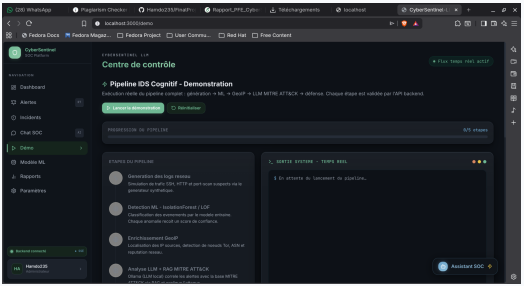
`pytest` + `vitest -run`

Démonstration en direct

Génération d'une attaque $\rightarrow$ détection $\rightarrow$ explication $\rightarrow$ validation et blocage

Ce qui fonctionne

- Détection ML en **moins de 50 ms**
- RAG sur **697 techniques** MITRE ATT&CK
- Explication LLM en **30 à 90 secondes**
- Blocage avec **validation humaine** obligatoire
- Interface temps réel (sans rechargement de page)
- **Tests automatisés** (backend + frontend)



Scénario de démonstration reproductible

Limites et perspectives

Limites actuelles

- Authentification simplifiée (côté frontend)
- Blocage iptables **affiché**, pas exécuté automatiquement
- Détection centrée sur le **SSH**

Perspectives

- Couvrir plus de types d'attaques (DDoS, injection...)
- Exécution automatique sécurisée des blocages
- Authentification renforcée (JWT, rôles)
- Adaptation au contexte tchadien (ANSICE)

Conclusion

En résumé

CyberSentinel-LLM montre qu'il est possible de construire, avec des outils **gratuits et locaux**, une plateforme qui **détecte**, **explique** et **aide à décider** — en gardant toujours **l'humain au centre**.

Contributions

- Moteur ML non supervisé (IF + LOF)
- RAG sur 697 techniques MITRE
- LLM local, 100% hors ligne
- Human-in-the-Loop intégré

Une première brique vers des outils de cybersécurité **accessibles** au contexte tchadien.

Merci pour votre attention

Questions ?